




WHITE PAPER



KI IM INDUSTRIELLEN PROBLEM- UND DEFECT-MANAGEMENT

VOM DEFECT ZUM ENTWICKLUNGSWISSEN

Ein branchenübergreifender Orientierungsrahmen für bessere Ticketqualität, weniger Koordinationsaufwand und systematisches Lernen aus gelösten Problemen.

Geschäftsführung: Dr. Michael Keckeisen
CR: Olaf Fischbach

WE COMBINE KNOWLEDGE, TECHNOLOGY, AND PRACTICAL EXPERIENCE.

Die Leitidee
Nicht nur Tickets schneller bearbeiten.
Erkenntnisse so zurückführen, dass
Entwicklung und Produkt davon profitieren



Inhaltsverzeichnis

ENTSCHEIDUNGSPERSPEKTIVE	3
PROZESS UND INTEGRATION	4
ZWEI KONKRETE HEBEL	5
NUTZEN UND NACHWEIS	6
FORSCHUNG UND SKALIERUNG	7
EINFÜHRUNG IN DIE PRAXIS	8
AUTOMOTIVE ALS ANWENDUNGSFALL	9
QUELLEN UND KONTAKT	10



1. ENTSCHEIDUNGSPERSPEKTIVE

Nicht die Zahl der Tickets ist das Ziel

Ein Test schlägt fehl. Eine Anlage zeigt ein unerwartetes Verhalten. Ein Kunde meldet eine Abweichung. Der technische Befund ist häufig erst der Anfang: Wer versteht das Problem, welche Informationen fehlen, wer übernimmt die Bearbeitung – und wie gelangt die Erkenntnis später zurück in die Entwicklung?

Dieses Whitepaper betrachtet Defect-Management als Verbindung zwischen Beobachtung, Entscheidung und Entwicklungswissen. Künstliche Intelligenz kann diese Verbindung unterstützen. Der vorgeschlagene Ansatz setzt nicht bei einem universellen KI-Agenten an, sondern bei klar begrenzten Aufgaben innerhalb bestehender Prozesse.

Drei Ziele für den Einstieg

Handlungsfähige Informationen: Beschreibungen präzisieren und Belege verknüpfen.

Weniger unnötige Koordination: Ähnliche Fälle finden und Zuständigkeiten vorbereiten.

Nachhaltiges Lernen: Geprüfte Erkenntnisse in Anforderungen und Tests zurückführen.

Was mit „Defect“ gemeint ist

Als Defect-Ticket wird hier die dokumentierte Beobachtung einer Abweichung verstanden. Es ist zunächst weder eine gesicherte Ursachenanalyse noch eine freigegebene Änderungsanforderung. Diese Unterscheidung bleibt auch dann wichtig, wenn KI eine plausible Erklärung formuliert.

Ein Muster, unterschiedliche Industrien

Die folgenden Situationen sind illustrative Übertragungen des Ansatzes, keine Referenzprojekte oder Wirksamkeitsnachweise.

Beispielkontext	Möglicher Befund	Gemeinsame Aufgabe
Automotive	Auffälligkeit in einer softwareintensiven Fahrzeugfunktion.	Version, Testbedingungen und zuständige Domäne klären.
Maschinen- und Anlagenbau	Störung im Zusammenspiel von Steuerung und Bedienung.	Beobachtung, Ablauf und betroffene Komponenten verbinden.
Energie- und Automatisierungstechnik	Abweichung an einer Geräte- oder Systemschnittstelle.	Betriebszustand, Konfiguration und technische Verantwortung zuordnen.
Industrielle Software	Fehlverhalten nach einer Integration oder Konfigurationsänderung.	Reproduktion, Abhängigkeiten und Regressionstest nachvollziehbar machen.

Der Ansatz beschreibt ein Zielbild und einen Einführungsweg. Er beansprucht keine identischen Effekte in unterschiedlichen Branchen und berichtet keine pauschalen Einsparquoten.



2. PROZESS UND INTEGRATION

KI dort einsetzen, wo Arbeit entsteht

Die vorhandene Werkzeuglandschaft bleibt der Ausgangspunkt. Ob Application Lifecycle Management (ALM), Product Lifecycle Management (PLM), Qualitätsmanagement oder Service-System: Tickets, Versionen und freigegebene Entscheidungen brauchen ein führendes System.

KI ergänzt diese Umgebung durch nachvollziehbare Vorschläge, nicht durch eine zweite, widersprüchliche Datenwelt.

Das nachfolgende Referenzmodell bündelt die Anwendungsfelder aus dem TWT-Ansatz. Es verbindet einzelne Assistenzfunktionen mit dem durchgängigen Informationsfluss und der fachlichen Prüfung ihrer Ergebnisse.

Prozessschritt	Geeignete Unterstützung	Was kontrolliert bleiben muss
1 Erfassen	Beobachtungen strukturieren; Informationen aus verfügbaren Quellen zusammenführen.	Herkunft, Version und Trennung von Beobachtung und Vermutung.
2 Prüfen und vergleichen	Vollständigkeit und Konsistenz prüfen; ähnliche oder doppelte Tickets vorschlagen.	Fehlende Angaben nicht erfinden; Ähnlichkeit nicht mit gleicher Ursache verwechseln.
3 Zuordnen	Mögliche Verantwortliche anhand von Inhalt, Metadaten und vergleichbaren Fällen priorisieren.	Unklare Zuständigkeiten und bereichsübergreifende Fälle gezielt eskalieren.
4 Analysieren und lösen	Logs und Beschreibungen aufbereiten; Hypothesen und relevante Belege zusammenstellen.	Reproduktion, Abhängigkeiten und Regressionstest nachvollziehbar machen.
5 Lernen und rückführen	Anforderungs- und Teständerungen aus bestätigten Lösungen vorbereiten.	Änderungen prüfen, freigeben und ihre Wirkung verifizieren.

Querschnitt: Transparenz für die Steuerung

Management-Zusammenfassungen und Cluster können den Überblick über Problemgruppen erleichtern. Sie sollten auf einzelne Tickets zurückführbar sein und zwischen beobachtetem Status, vermuteten Zusammenhängen und vorgeschlagenen Prioritäten unterscheiden.

Eine Priorisierung durch KI ersetzt keine fachliche Entscheidung über Kritikalität und Produktziele.

Die kleinste brauchbare Datenbasis

Vor dem Modell stehen konsistente Ticket-IDs, nachvollziehbare Versionen, ein verständliches Zustandsmodell und verknüpfte Belege. Bestehende Berechtigungen müssen auch für Suchindizes, Modellkontext und Protokolle gelten. Fehlende oder widersprüchliche Daten werden als solche sichtbar gemacht – nicht sprachlich geglättet.



3. ZWEI KONKRETE HEBEL

Bessere Informationen. Besseres Lernen.

Hebel 1: Aus einer Meldung wird ein bearbeitbarer Fall

„Funktion geht manchmal nicht“ beschreibt ein Symptom, aber noch keinen reproduzierbaren Fall. Eine Qualitätsassistenz kann nach Bedingungen, Versionen, erwartetem und beobachtetem Verhalten fragen. Dass zwischen benötigten und gelieferten Informationen eine Lücke bestehen kann, ist bereits in der Forschung zur Qualität von Bug Reports beschrieben [1].

Illustratives Beispiel – kein Kundenbefund

Meldung: „Das Bedienpanel zeigt nach dem Aufwecken einen alten Anlagenzustand.“

Sinnvolle KI-Rückfragen: Welcher Softwarestand? Welcher Übergang in den Ruhezustand? Welche Anzeige wird erwartet? Liegen Zeitstempel oder Logs vor?

Nicht sinnvoll: Eine konkrete Fehlerursache oder fehlende Versionsnummer ohne Beleg ergänzen.

Im Ergebnis steht nicht einfach mehr Text, sondern eine besser prüfbare Beschreibung. Pflichtfelder lassen sich regelbasiert kontrollieren. Semantische Unklarheiten benötigen gegebenenfalls ein Sprachmodell.

Hinweise aus ähnlichen Tickets sollten mit Quellen versehen und von der meldenden Person bestätigt werden.

Ähnlichkeit unterstützt die Bearbeitung – sie entscheidet sie nicht

Die Suche nach doppelten Fehlerberichten ist ein etabliertes Forschungsfeld [2]. Für die Praxis ist eine Rangliste möglicher Treffer oft hilfreicher als ein vorschnelles Zusammenführen. Zwei gleich klingende Meldungen können verschiedene Ursachen haben. Umgekehrt können unterschiedlich formulierte Beobachtungen auf denselben Defect zurückgehen. Die Bestätigung und die ursprünglichen Belege bleiben nachvollziehbar.

Hebel 2: Aus einer Lösung wird überprüfbares Wissen

Ein geschlossenes Ticket verhindert noch keine Wiederholung. Der zweite Hebel fragt deshalb: Fehlt eine Anforderung, ist sie missverständlich oder wurde eine vorhandene Anforderung falsch umgesetzt? Erst danach wird entschieden, ob die Spezifikation, ein Test oder die Implementierung geändert werden muss.

KI kann einen Änderungsvorschlag formulieren und passende Stellen in der Spezifikation suchen. Die fachliche Prüfung umfasst beabsichtigtes Verhalten, Widersprüche, betroffene Varianten und Verifizierbarkeit. Der Wissenskreislauf schließt sich erst mit der freigegebenen Änderung und einem geeigneten Test – nicht mit der Generierung eines Satzes.

Geschlossener Wissenskreislauf

Beobachtung → validierte Ursache und Lösung → geprüfte Änderung → Anforderung / Test / Implementierung → Verifikation und erneute Nutzung.



4. NUTZEN UND NACHWEIS

Messen, was tatsächlich besser wird

Eine überzeugende Demonstration ist noch kein Wirtschaftlichkeitsnachweis. Der vorgeschlagene Bewertungsrahmen unterscheidet zwischen Qualität der Assistenz, Wirkung auf den Arbeitsprozess und zusätzlichem Betriebsaufwand. Messgröße, Vergleichsbasis und Akzeptanzkriterien sollten vor dem Pilotbetrieb feststehen.

Frage	Geeignete Messgröße	Worauf zu achten ist
Wird ein Ticket besser?	Beobachtungen strukturieren; Informationen aus verfügbaren Quellen zusammenführen.	Herkunft, Version und Trennung von Beobachtung und Vermutung.
Werden relevante Fälle gefunden?	Vollständigkeit und Konsistenz prüfen; ähnliche oder doppelte Tickets vorschlagen.	Fehlende Angaben nicht erfinden; Ähnlichkeit nicht mit gleicher Ursache verwechseln.
Stimmt die Zuständigkeit?	Mögliche Verantwortliche anhand von Inhalt, Metadaten und vergleichbaren Fällen priorisieren.	Unklare Zuständigkeiten und bereichsübergreifende Fälle gezielt eskalieren.
Wird die Bearbeitung effizienter?	Logs und Beschreibungen aufbereiten; Hypothesen und relevante Belege zusammenstellen.	Reproduktion, Abhängigkeiten und Regressionstest nachvollziehbar machen.
Wird Wissen wiederverwendet?	Geprüfte Änderungen mit Rückverweis auf Defect und Verifikation.	Verknüpfungen allein beweisen keine höhere Produktqualität.
Lohnt sich die Assistenz insgesamt?	Gesamtkosten und Energie je akzeptiertem Ergebnis.	Fehlversuche, Nacharbeit, Review und Betrieb mitrechnen.

Ein pragmatischer Vergleich

Zunächst werden historische Fälle mit einer zeitlich getrennten Testmenge und einem einfachen Vergleichsverfahren untersucht. Dabei dürfen nur Informationen einfließen, die zum damaligen Bearbeitungszeitpunkt bereits vorlagen. Danach folgt die Bewertung im realen Prozess. Fachliche Reviewer nutzen gemeinsame Kriterien; Stichprobengröße, Ausschlüsse und Uneinigkeit werden dokumentiert.

Ein reiner Vorher-nachher-Vergleich kann durch andere Produktstände oder Teamstrukturen verzerrt sein. Modellgüte und Prozessnutzen sind deshalb getrennt auszuweisen. Werden mehr Fehler früh entdeckt, ist eine steigende Zahl an Tickets nicht automatisch ein negatives Ergebnis.

Wirtschaftlichkeit je akzeptiertem Ergebnis

Berücksichtigt werden Modell- und Infrastrukturkosten, Prüfung, Nacharbeit sowie anteilige Integration und Betrieb. Eingesparte Zeit wird erst mit offen gelegten Annahmen in einen monetären Nutzen übersetzt. Der Energiebedarf erhält eine eigene, klar benannte Systemgrenze.



5. FORSCHUNG UND SKALIERUNG

Drei Fragen für den nächsten Schritt

1. Wie orchestrieren wir KI zuverlässig?

Einzelne Assistenten zu verbinden ist mehr als eine zusätzliche Schnittstelle. Die Forschung zu Multi-Agenten-Systemen beschreibt Fehler unter anderem im Systemdesign, in der Abstimmung zwischen Agenten und in der Ergebnisprüfung [3]. Für das Defect-Management leiten wir daraus begrenzte Zuständigkeiten, klar definierte Übergaben und nachvollziehbare Entscheidungen ab.

Nicht jeder Prozess braucht mehrere Agenten. Ein fester Workflow mit definierten Werkzeugen kann der geeignetere Ausgangspunkt sein. Wichtig sind Abbruchbedingungen, begrenzte Wiederholungen und ein manueller Rückfallpfad. Kritische Schreibzugriffe werden kontrolliert; eingelesene Tickettexte dürfen keine Prozessregeln oder Zugriffsrechte überschreiben.

2. Wie steuern wir Kosten und Energie?

Das passende Modell ist dasjenige, das die konkrete Aufgabe mit ausreichender Qualität innerhalb der festgelegten Ressourcen- und Zeitgrenzen erfüllt. RouteLLM untersucht die Modellauswahl zwischen unterschiedlich leistungsfähigen Sprachmodellen zur Balance von Kosten und Antwortqualität [4]. Ein industrieller Einsatz muss diese Balance an eigenen Aufgaben überprüfen.

TWT-Forschungsbezug: From Tokens to Watt-hours

Die von TWT mitverfasste Arbeit beschreibt eine analytische, empirisch kalibrierte Abschätzung der GPU-seitigen Inferenzenergie. Sie trennt Eingabeverarbeitung und Ausgabeerzeugung und berücksichtigt Rechenarbeit sowie Speicherbewegungen auf H100-Klasse-Hardware [5].

Der Ansatz unterstützt Entwurfsvergleiche. Er ersetzt weder die Messung des konkreten Betriebs noch eine vollständige Energie- oder CO₂-Bilanz des Dienstes.

Für die Orchestrierung schlagen wir vor, Qualität, Latenz, Kosten und Energie getrennt zu messen und gemeinsam zu begrenzen. Bewertet wird der gesamte Weg zu einem akzeptierten Ergebnis einschließlich Wiederholungen und Prüfung. Ein günstiger Einzelaufruf ist wenig wert, wenn er aufwendige Nacharbeit verursacht.

3. Worauf soll sich der Mensch konzentrieren?

Auf Innovation. Gemeint ist mehr Freiraum für bessere Konzepte, gezielte Experimente und fundierte Produktentscheidungen. Die Verantwortung für Anforderungen, Risiken und Freigaben bleibt ausdrücklich zugeordnet. Entlastung darf nicht dadurch schöngerechnet werden, dass notwendige Prüfung im Prozess unsichtbar wird.

Die Forschungsagenda verbindet zuverlässige Abläufe, einen bewussten Ressourceneinsatz und mehr Freiraum für die Arbeit am Produkt. Der jeweils sinnvolle Automatisierungsgrad folgt aus den Ergebnissen der Evaluation.



6. EINFÜHRUNG IN DIE PRAXIS

Klein beginnen. Kontrolliert erweitern.

Für den Einstieg empfiehlt dieser Orientierungsrahmen einen abgegrenzten Prozessschritt mit erkennbarer Reibung, verfügbarem Datenzugang und prüfbarem Ergebnis. Ticketqualität oder die Suche nach ähnlichen Fällen können dafür geeignete Kandidaten sein. Die konkrete Wahl hängt von Datenreife, Fehlerrisiko und Integrationsaufwand ab.

Phase	Konkretes Arbeitsergebnis	Kriterium für den nächsten Schritt
1 Aufgabe und Ausgangslage klären	Prozessgrenze, Verantwortliche, Datenquellen und heutige Bearbeitung beschreiben.	Es gibt eine messbare Fragestellung und nutzbare, zulässig zugängliche Daten.
2 Offline vergleichen	Repräsentative Prüffälle, Baseline und fachliches Bewertungsraster aufbauen.	Repräsentative Prüffälle, Baseline und fachliches Bewertungsraster aufbauen.
3 Assistiert pilotieren	Vorschläge in die vorhandene Oberfläche integrieren; Feedback und Aufwand erfassen.	Die Unterstützung bewährt sich im Ablauf, einschließlich Review und Rückfallpfad.
4 Begrenzt skalieren	Geeignete Aufgaben automatisieren; Betrieb, Budgets und Monitoring verankern.	Qualität bleibt unter wechselnden Bedingungen überprüfbar; ein verantwortlicher Betrieb ist gesichert.

Prozessverantwortung ist Teil der Lösung

Der Fachbereich legt fest, was ein korrektes Ergebnis ist und wer über Änderungen entscheidet. Daten- und IT-Verantwortliche sichern Zugriff, Versionierung und Integration. Das KI-Team verantwortet Evaluation und Modelländerungen; der Betrieb überwacht Verfügbarkeit, Fehler und Ressourcenverbrauch. Diese Aufgaben müssen zugeordnet sein, auch wenn sie in einer kleinen Organisation bei denselben Personen liegen.

Was vor einem Rollout beantwortet sein sollte

Wer darf welche Daten nutzen? Wann wird ein Vorschlag nicht ausgegeben? Wer entscheidet bei widersprüchlichen Belegen? Wie werden Modell- und Prozessänderungen erneut geprüft? Was passiert bei Ausfall oder zu hohen Kosten? Ohne klare Antworten sollte eine Assistenz nicht stillschweigend zur autonomen Entscheidung werden.

Der erste Workshop braucht keinen fertigen KI-Stack

Ein konkreter Prozess, repräsentative Tickets, die beteiligten Rollen und eine belastbare Beschreibung des heutigen Aufwands reichen als Ausgangspunkt. Erst daraus folgen die Anforderungen an Daten, Methoden und Werkzeuge.



7. AUTOMOTIVE ALS ANWENDUNGSFALL

BMW und TWT: vom Ticket zum Produkt

Der gemeinsame Beitrag von Dr. Michael Keckeisen (TWT) und Michael Adam (BMW Group) zur ELIV 2026 adressiert „AI Supported Problem & Defect Management for Complex Automotive Systems“. Das veröffentlichte Programm nennt datengetriebenes Defect-Management, semantische Ähnlichkeit und Duplikaterkennung, KI-unterstützte Ticketerstellung, Klassifikation und Routing sowie Erfahrungen, Kennzahlen und Governance [6].

Das begleitende Tagungsbandmanuskript erläutert die Einbettung in eine vorhandene ALMLandschaft und zwei ausgewählte Workflows: die Verbesserung der Ticketqualität sowie die Rückführung von Wissen aus gelösten Defects in die Spezifikation. Es ergänzt diese Perspektive um ein vorgeschlagenes Bewertungsmodell und die drei Fragen zu Orchestrierung, Ressourcen und menschlicher Innovation [7].

Was der Fall zeigt – und was daraus nicht folgt

Der BMW-Bezug veranschaulicht einen konkreten Anwendungskontext in der automobilen Entwicklung. Dieses Whitepaper berichtet keine freigegebenen BMW-Kennzahlen und leitet daraus keine branchenübergreifenden Einsparquoten ab. Die weitergehenden Empfehlungen sind ein TWT-Orientierungsrahmen, keine gemeinsame BMW-Positionierung.

Prozessverantwortung ist Teil der Lösung

Übertragbares Prinzip	Was jede Organisation selbst prüfen muss
Assistenz im vorhandenen Prozess verankern.	Führende Systeme, Zugriffsrechte und Schnittstellen.
Informationsqualität vor Automatisierung verbessern.	Fachliche Begriffe, Pflichtangaben und verfügbare Belege.
Ähnlichkeit und Zuständigkeit prüfbar machen.	Domänenspezifische Labels, Verantwortung und Eskalationen.
Nach Nutzen statt nach Modellgröße skalieren.	Lokale Qualitätsschwellen, Review-Aufwand und Betriebsgrenzen.

Weiterführender Beitrag

Vortrag: ELIV 2026, Baden-Baden, 14.–15. Oktober 2026; im veröffentlichten Programm auf Seite 13 [6].

Paper: Keckeisen / Adam, gleichnamiges Tagungsbandmanuskript, Entwurfsfassung September 2026 [7].

Die allgemeine Methodik dieses Whitepapers ist unabhängig von der Veranstaltung anwendbar. BMW wird ausschließlich als referenzierter Anwendungsfall behandelt.



8. QUELLEN UND KONTAKT

Vertiefen und konkret werden

Das Ziel ist ein bearbeitbarer erster Anwendungsfall: Welche Information fehlt heute, welche Entscheidung lässt sich unterstützen und woran wird der Nutzen erkennbar? Die Antwort darauf ist die Grundlage für einen belastbaren Pilot – nicht die Wahl eines möglichst großen Modells.

Literatur und weiterführende Quellen

1. Bettenburg, N. et al.: What Makes a Good Bug Report? FSE 2008, pp. 308–318. [doi:10.1145/1453101.1453146](https://doi.org/10.1145/1453101.1453146).
2. Sun, C. et al.: A Discriminative Model Approach for Accurate Duplicate Bug Report Retrieval. ICSE 2010, Vol. 1, pp. 45–54. [doi:10.1145/1806799.1806811](https://doi.org/10.1145/1806799.1806811).
3. Cemri, M. et al.: Why Do Multi-Agent LLM Systems Fail? 2025. [arXiv:2503.13657v3](https://arxiv.org/abs/2503.13657v3).
4. Ong, I. et al.: RouteLLM: Learning to Route LLMs with Preference Data. 2024, revidiert 2025. [arXiv:2406.18665v4](https://arxiv.org/abs/2406.18665v4).
5. Vartziotis, T. et al.: From Tokens to Watt-hours: Analytical Energy Estimation for LLM Inference on Modern GPUs. 2026. [arXiv:2607.26571v1](https://arxiv.org/abs/2607.26571v1).
6. VDI Wissensforum: ELIV 2026 – Program, S. 13. Vortrag von M. Keckeisen und M. Adam: AI Supported Problem & Defect Management for Complex Automotive Systems. [Programm und PDF](#).
7. Keckeisen, M.; Adam, M.: AI-Supported Problem & Defect Management for Complex Automotive Systems. Begleitendes Tagungsbandmanuskript zur ELIV 2026. Entwurfsfassung September 2026; noch nicht veröffentlicht.
8. TWT GmbH Science & Innovation: Über uns. Unternehmensprofil und Leistungsfelder. twi-innovation.de/de/ueber-uns/.

Webquellen geprüft im September 2026. Forschungsarbeiten dienen als methodischer Hintergrund; ihre Ergebnisse sind keine BMW-Projektkennzahlen.

Über TWT

TWT verbindet wissenschaftliche Methoden mit Software-, Produkt- und Prozessentwicklung sowie Industrieforschung. Der branchenübergreifende Anspruch umfasst unter anderem Automotive, Aerospace, Healthcare und Energy [8]. Für das Defect-Management steht hier der Transfer von Forschung in nachvollziehbare Engineering-Prozesse im Mittelpunkt.

Kontakt

Olaf Fischbach • olaf.fischbach@twi-gmbh.de

Dr. Michael Keckeisen • michael.keckeisen@twi-gmbh.de


TWT GmbH Science & Innovation · Industriestraße 6 · 70565 Stuttgart twi-innovation.de

Erfahren Sie mehr über uns



Wir gestalten die Zukunft der digitalen Entwicklung

Seit über 40 Jahren steht TWT für die Verbindung von Wissenschaft und Wirtschaft. Als innovativer Technologiepartner entwickeln wir ganzheitliche Lösungen für die digitale Transformation - von der Forschung bis zur Serienreife. In interdisziplinären Teams vereinen wir Kompetenzen aus Ingenieurwesen, Informatik und Data Science, um komplexe Herausforderungen mit intelligenten Technologien zu lösen. Mit unserer Expertise in Künstlicher Intelligenz, Machine Learning und Digital Engineering **treiben wir die Produktentwicklung von morgen voran** - nachhaltig, effizient und zukunftssicher



WE KNOW HOW.



Bildquelle: Adobe Stock